Home Loan Approval by Linear Regression ML Model

Arturo Verdu

Descripción del problema:

Nuestro cliente quiere hacer un modelo usando IA para automatizar el proceso de elegibilidad de prestamos bancarios basándose en el perfil del cliente, con detalles como Genero, Estado Civil, Educación, Numero de Dependientes, Ingresos, Historial de Crédito, Monto de Préstamo, Plazo de Pago del Préstamo, Ubicación de la propiedad y si trabaja por cuenta propia.
Es un problema de clasificación, la meta es evitar la mayor cantidad de malos clientes que no puedan pagar los prestamos otorgados.

En este caso nuestra medida de éxito será el recall, ya que queremos reducir el numero de falsos negativos.

Para esto usaremos la biblioteca de sci-kit learn,

específicamente aquellas de sklearn.metrics

para determinar las medidas requeridas.

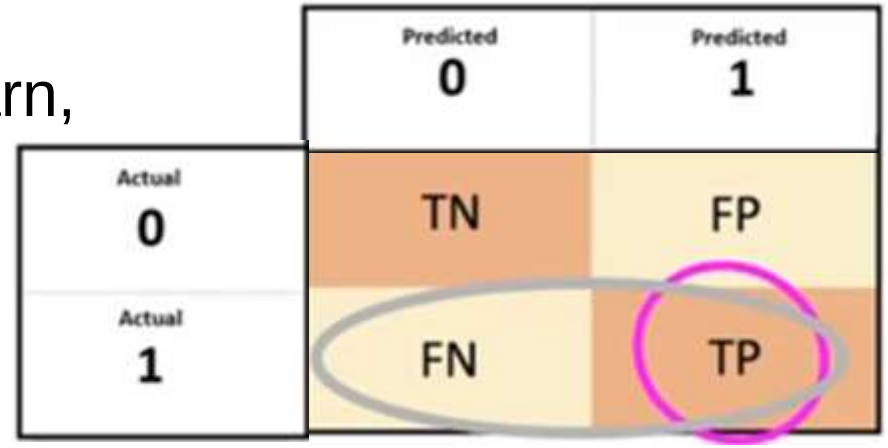

Columna/Variable	Descripción	Tipo de Variable	Importancia Inicial	Nota
Loan_ID	Numero de Identificación único para los prestamos de cada cliente.	Índice Único		Identificador único, útil para encontrar outliers o missing data
Gender	Genero del cliente, masculino o femenino.	Categórica	2	Demográfica
Married	Estado civil del cliente, Casado o Soltero.	Categórica	2	Demográfica
Dependents	Numero de personas dependientes del cliente.	Categórica	2	Demográfica
Education	Nivel de educación del cliente.	Categórica	1	Demográfica
Self Employed	Si el cliente trabaja por cuenta propia o no.	Categórica	1	Demográfica
Applicant Income	Ingresos del cliente.	Numérica Categórica	0	Indica el poder adquisitivo y potencial de préstamo del cliente
Coapplicant Income	Ingresos de coaplicante del cliente, puede ser de la pareja, familia, etc.	Numérica Categórica	1	Indica el poder adquisitivo condicional del cliente
Loan Amount	Monto para prestar al cliente (en miles).	Numérica Categórica	0	Indica el monto a prestar al cliente de parte del banco
Loan Amount Term	Tiempo para pagar el préstamo (en meses).	Numérica Categórica	1	Indica el tiempo en que se pagara el préstamo
Credit History	Historial de crédito del cliente.	Numérica Categórica	0	Si el historial de crédito del cliente esta en regla
Property Area	Donde se ubica la propiedad sujeta al préstamo.	Categórica	1	Ubicación de la casa relevante al préstamo
Loan Status	Si el préstamo es aprobado o no.	Categórica	0	Resolución del préstamo

Hipótesis de features:

Nuestro target a simple vista es la columna de “Loan_Status”, esta se usará de target para nuestro modelo de Machine Learning.

Nuestras features a simple vista son;

- **Credit_History:** Si el cliente tiene historial de pagos con el banco esto demuestra que el cliente siempre ha pagado sus deudas con el banco, y que pagara aquellas del préstamo también.
- Education/Self_Employed: Si el cliente tiene un mayor nivel de educación entonces tiene seguridad laboral y un ingreso fijo, en cambio si trabaja en cuenta propia su ingreso varia y puede que pierda la posibilidad de pagar el préstamo.
- **ApplicantIncome:** El ingreso del cliente nos demuestra si el cliente puede pagar los gastos que conlleva el préstamo.
- Gender/Married/CoapplicantIncome/Dependents: Si el cliente esta casado puede tener mayor posibilidad debido a un posible doble ingreso en la propiedad, mientras que una mayor cantidad de Dependientes reduzca el ingreso ya que tiene que invertirse en ellos.
- **LoanAmount/LoanAmountTerm:** El monto a prestar de parte del banco y el tiempo en el que el cliente pagara el préstamo.
- Property_Area: Donde la propiedad esta ubicada, Urbana, Semiurbana o Rural.

EDA: Tratamiento de Outliers

	ApplicantIncome	CoapplicantIncome	LoanAmount	Loan_Amount_Term	Credit_History
count	614.000000	614.000000	592.000000	600.00000	564.000000
mean	5403.459283	1621.245798	146.412162	342.00000	0.842199
std	6109.041673	2926.248369	85.587325	65.12041	0.364878
min	150.000000	0.000000	9.000000	12.00000	0.000000
25%	2877.500000	0.000000	100.000000	360.00000	1.000000
50%	3812.500000	1188.500000	128.000000	360.00000	1.000000
75%	5795.000000	2297.250000	168.000000	360.00000	1.000000
max	81000.000000	41667.000000	700.000000	480.00000	1.000000

Se pueden apreciar outliers en las columnas de ApplicantIncome, CoapplicantIncome y LoanAmount, gráficamente se nota el daño a los datos:

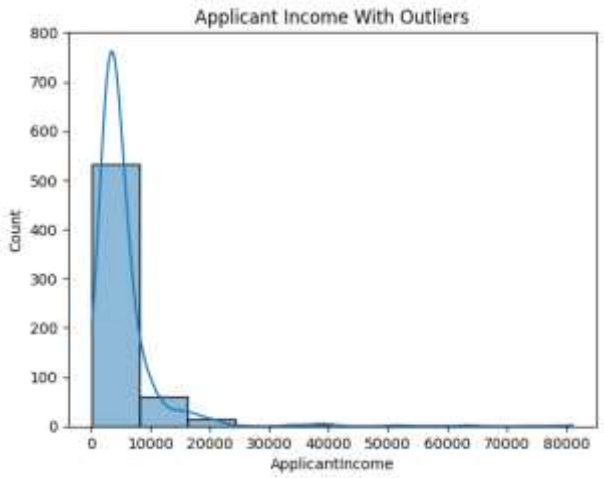

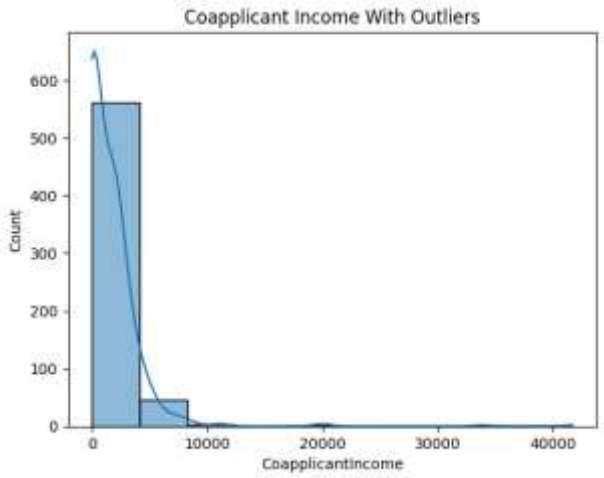

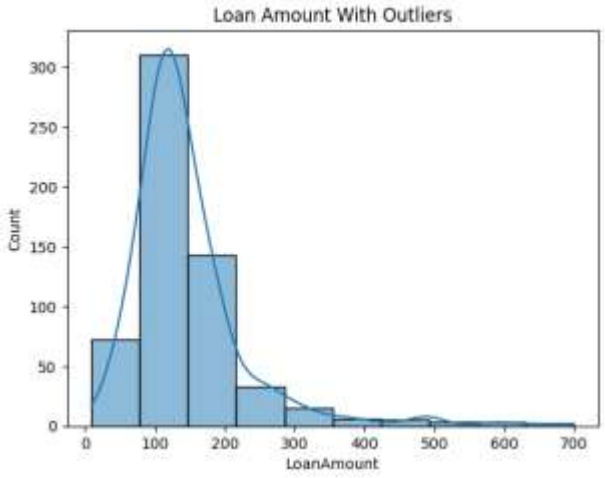

Luego de remover los outliers, solo se ha reducido el total de los datos por 5%, pero todo se ve mejor ajustado:

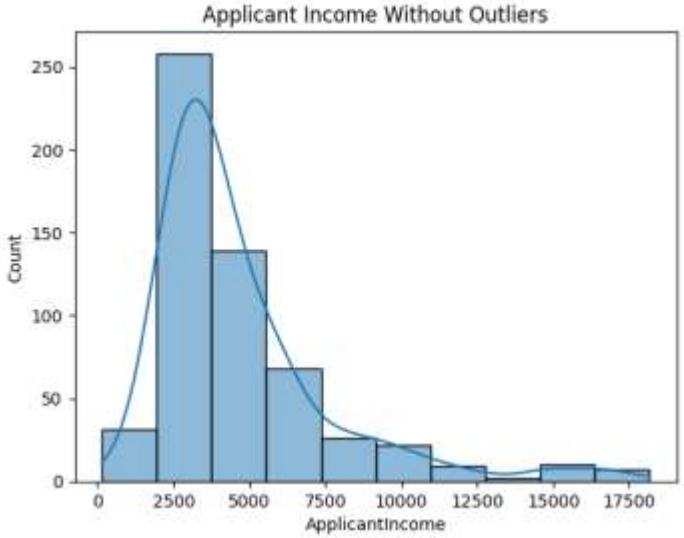

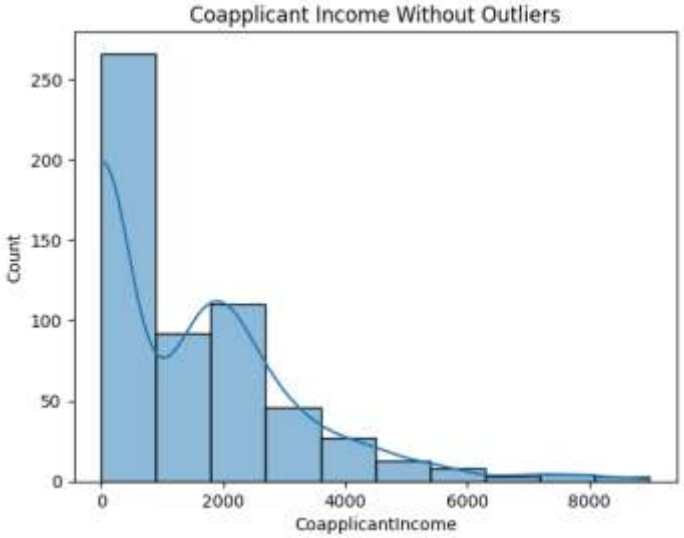

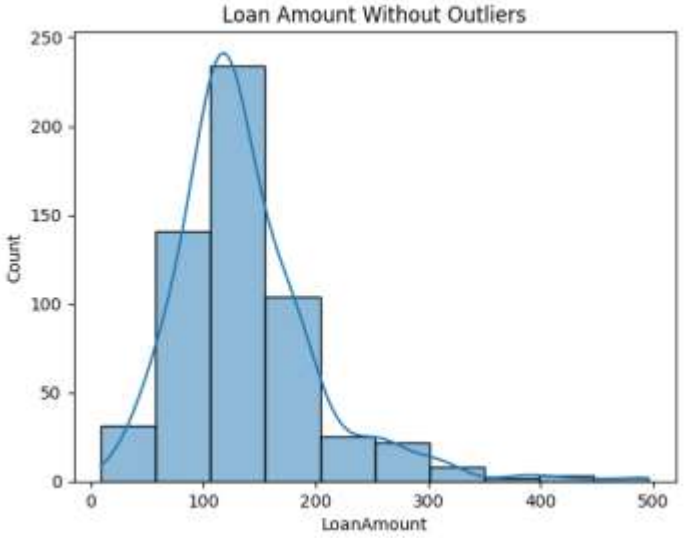

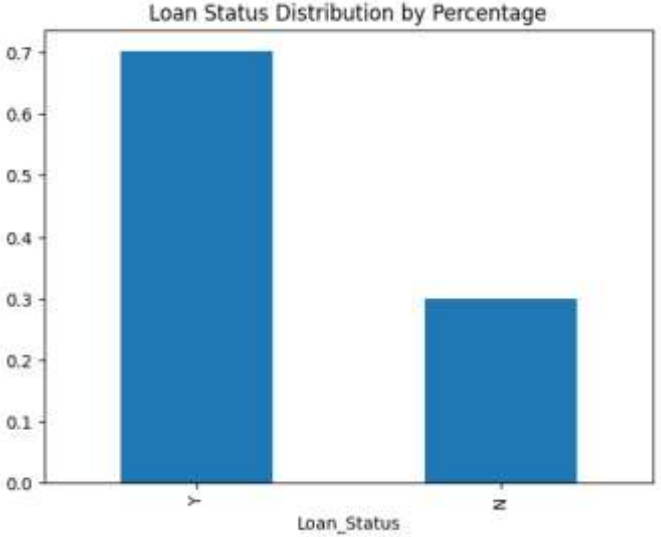

La distribución del target total es cerca de 70/30, sin considerar features, suficientes para clasificarlo de forma significativa.

Tratamiento de datos faltantes

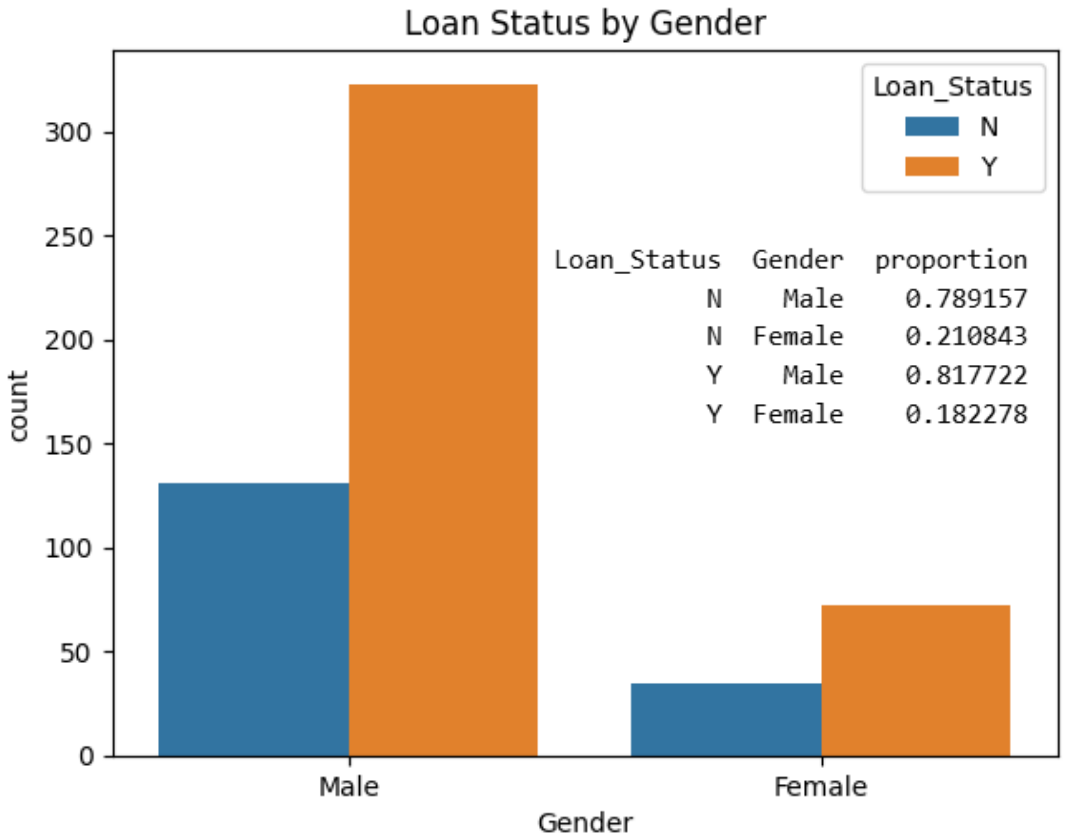

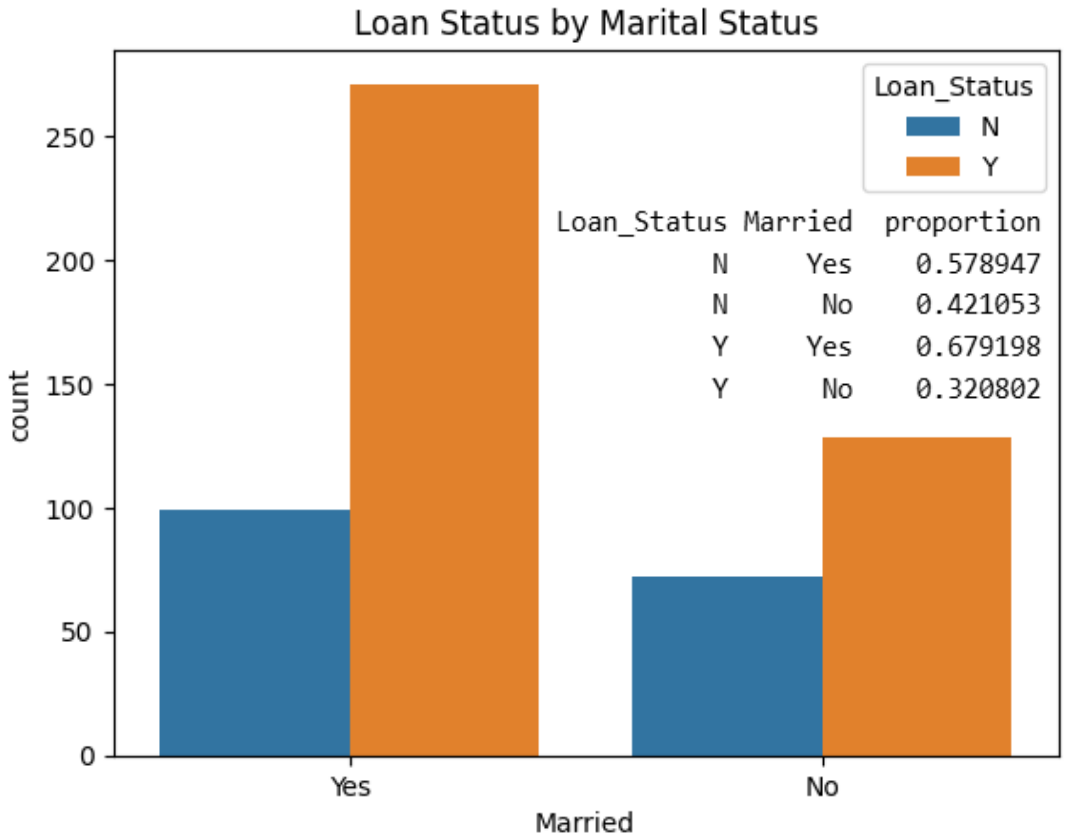

Se puede observar una diferencia pequeña entre Genero y una significativa presente entre Estado civil, mientras que solo había 3 datos faltantes en "*Married*", los datos faltantes en "*Gender*" no son tan significativos y se reemplazaron con datos aleatorios.

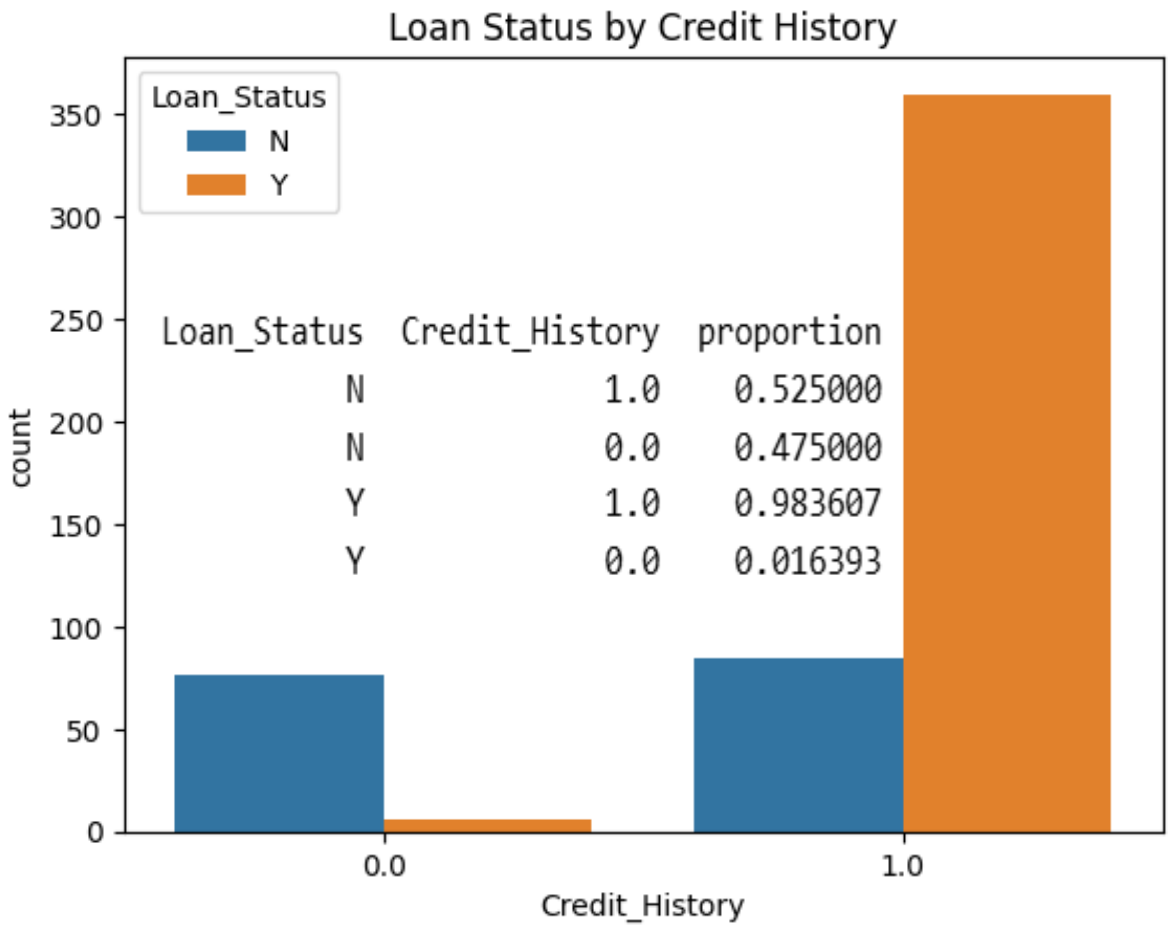

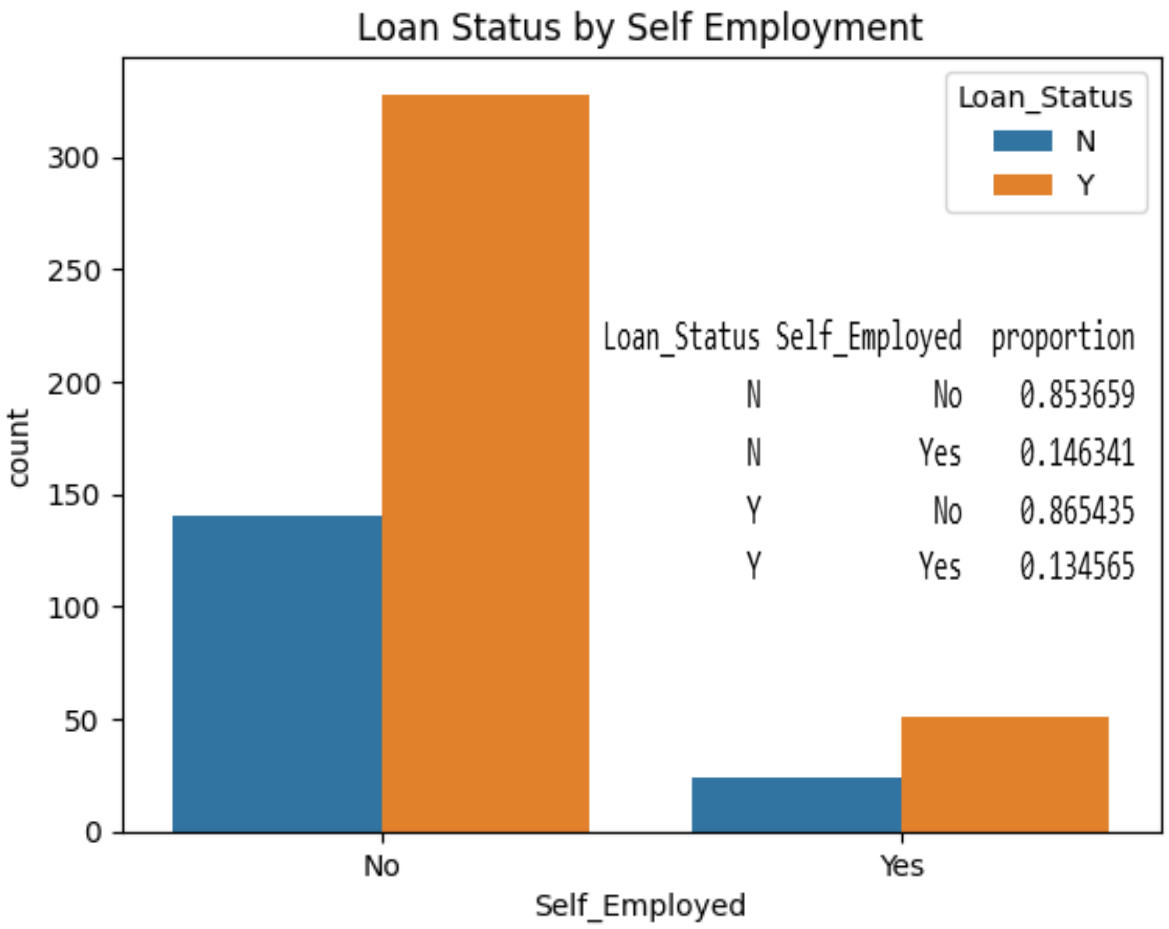

Entre los datos faltantes en "*Self_Employment*" solo se presento una diferencia de 1%, no muy significativa así que los valores faltantes se reemplazaron por valores aleatorios. Mientras tanto "*Credit_History*" demuestra un valor monumental para la aprobación de prestamos, los datos faltantes en este serán reemplazados por la moda (1.0) para tener mas datos negativos y evitar sobrecargar el modelo con resultados positivos cuando "*Credit_History*" es positivo.

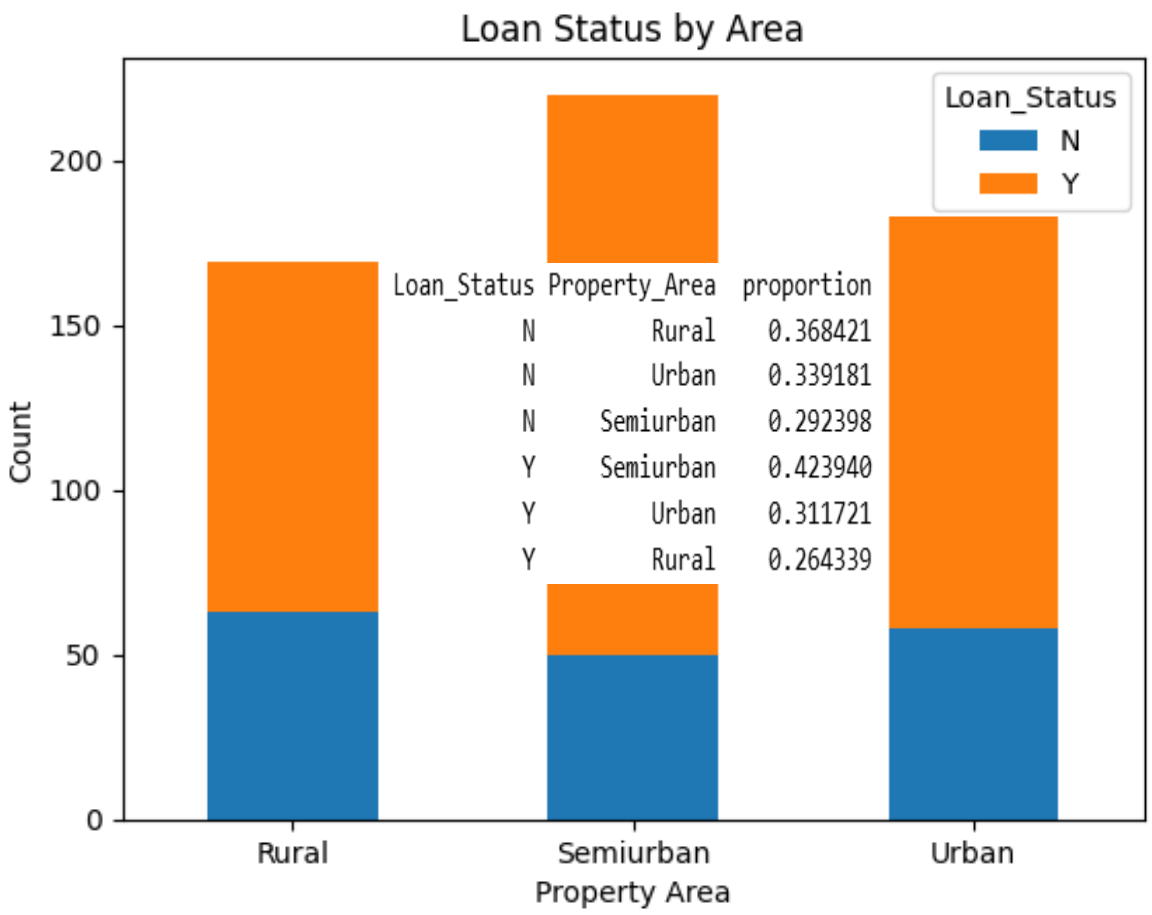

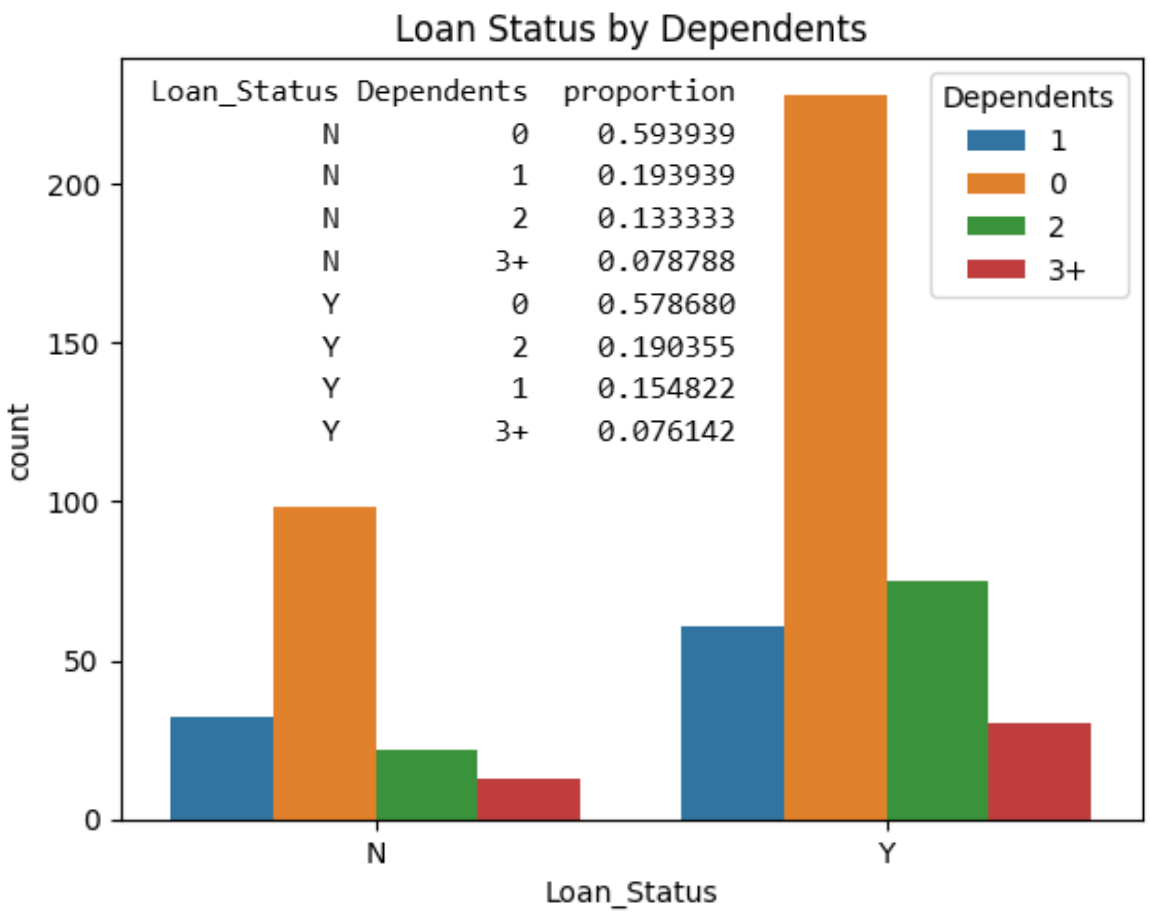

No se demuestra un valor significativo entre el numero de dependientes y la aprobación de un préstamo, los datos faltantes de *“Dependents”* se rellenaron con datos aleatorios, mientras que el área parece demostrar mas aprobación cuando se solicita el préstamo para áreas Semiurbanas.

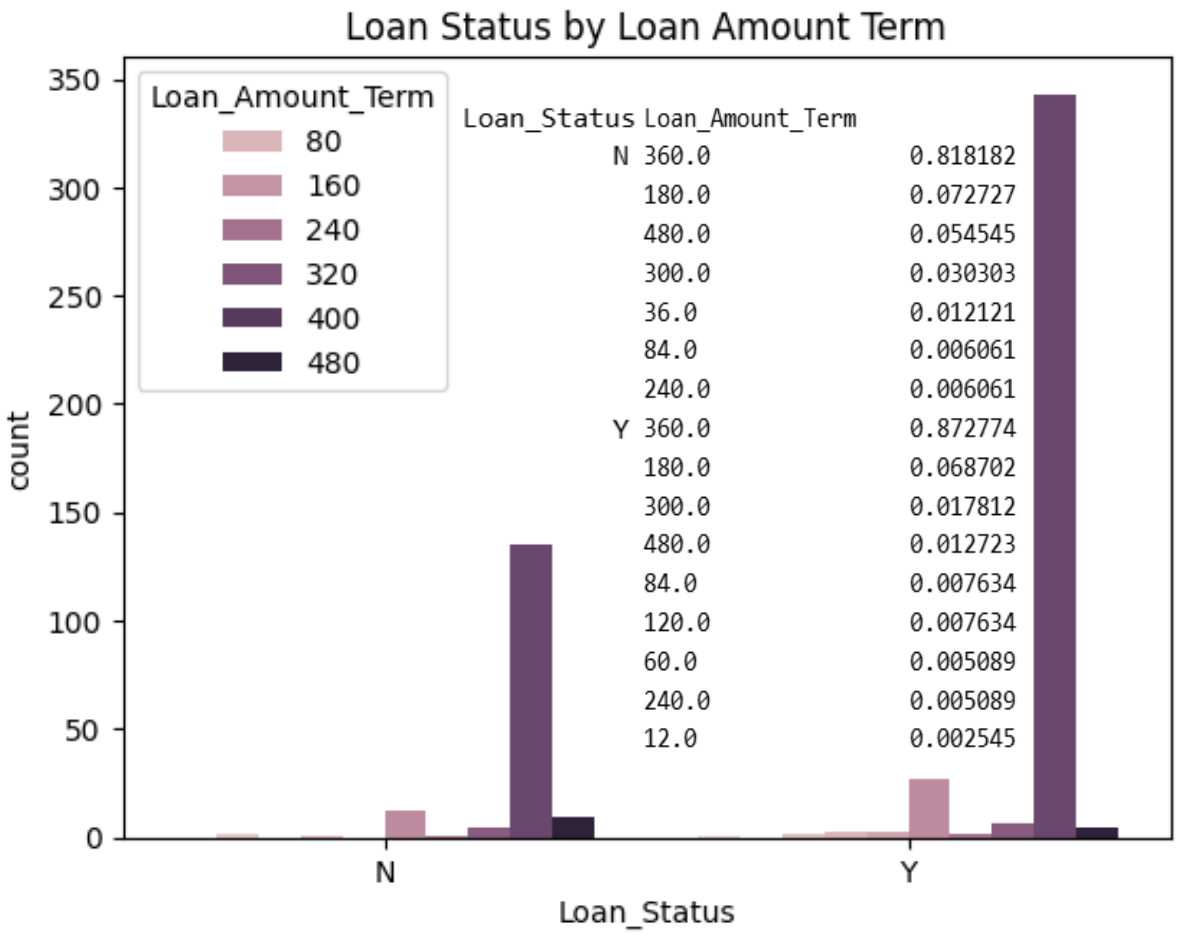

Loan_Status	Loan_Amount_Term	
N	360.0	0.818182
	180.0	0.072727
	480.0	0.054545
	300.0	0.030303
	36.0	0.012121
	84.0	0.006061
	240.0	0.006061
Y	360.0	0.872774
	180.0	0.068702
	300.0	0.017812
	480.0	0.012723
	84.0	0.007634
	120.0	0.007634
	60.0	0.005089
	240.0	0.005089
	12.0	0.002545

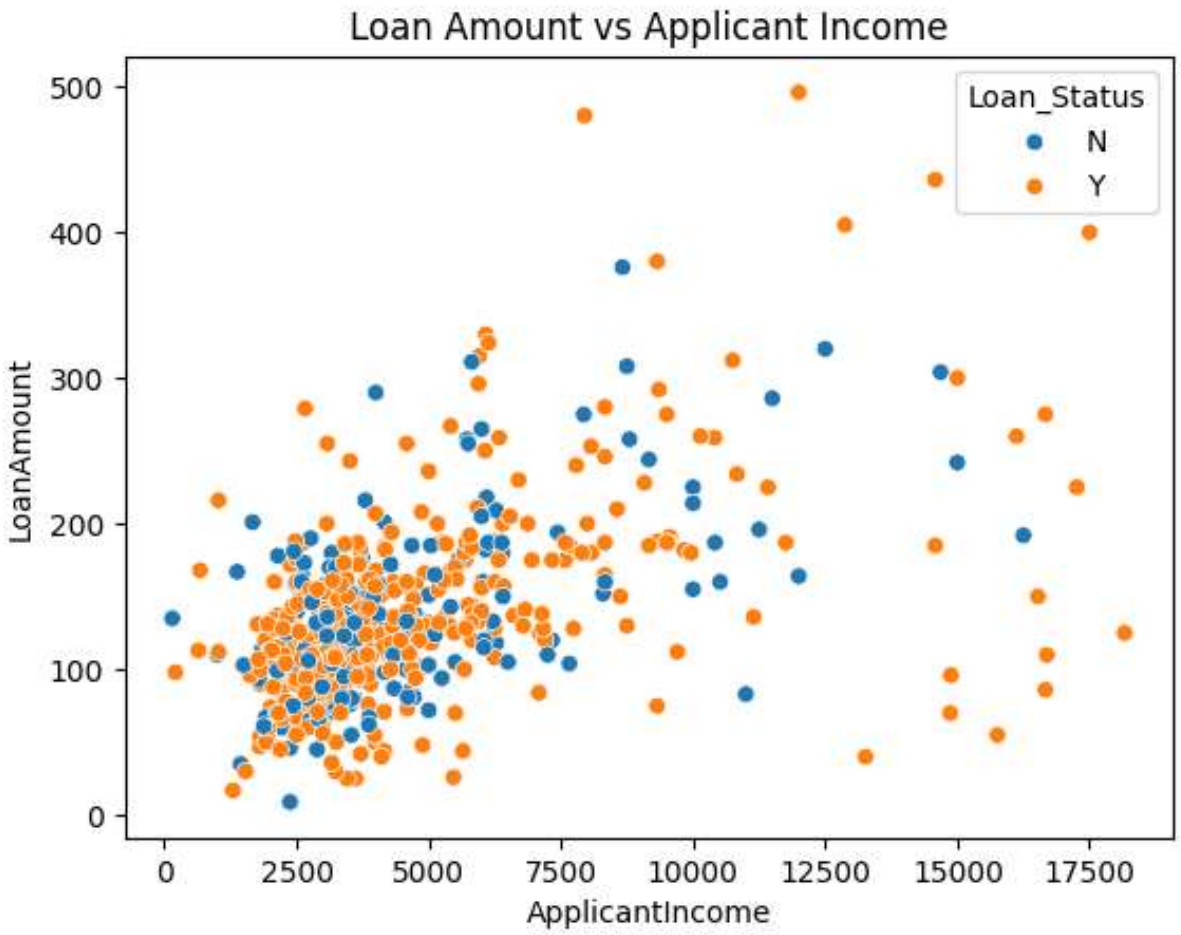

Entre todos los "*Loan_Amount_Term"* se aprecia que los prestamos con mayor de 360 días tienen mayor probabilidad de ser aprobados, mientras que aquellos con menos de 300 días son rechazados.

Mientras tanto, no se observa un valor significativo entre las aprobaciones por monto de préstamo o de ingresos del cliente, aunque no se vea mucho valor, a los datos faltantes de este ultimo se les aplica la media para no dispersar los datos de manera radical.

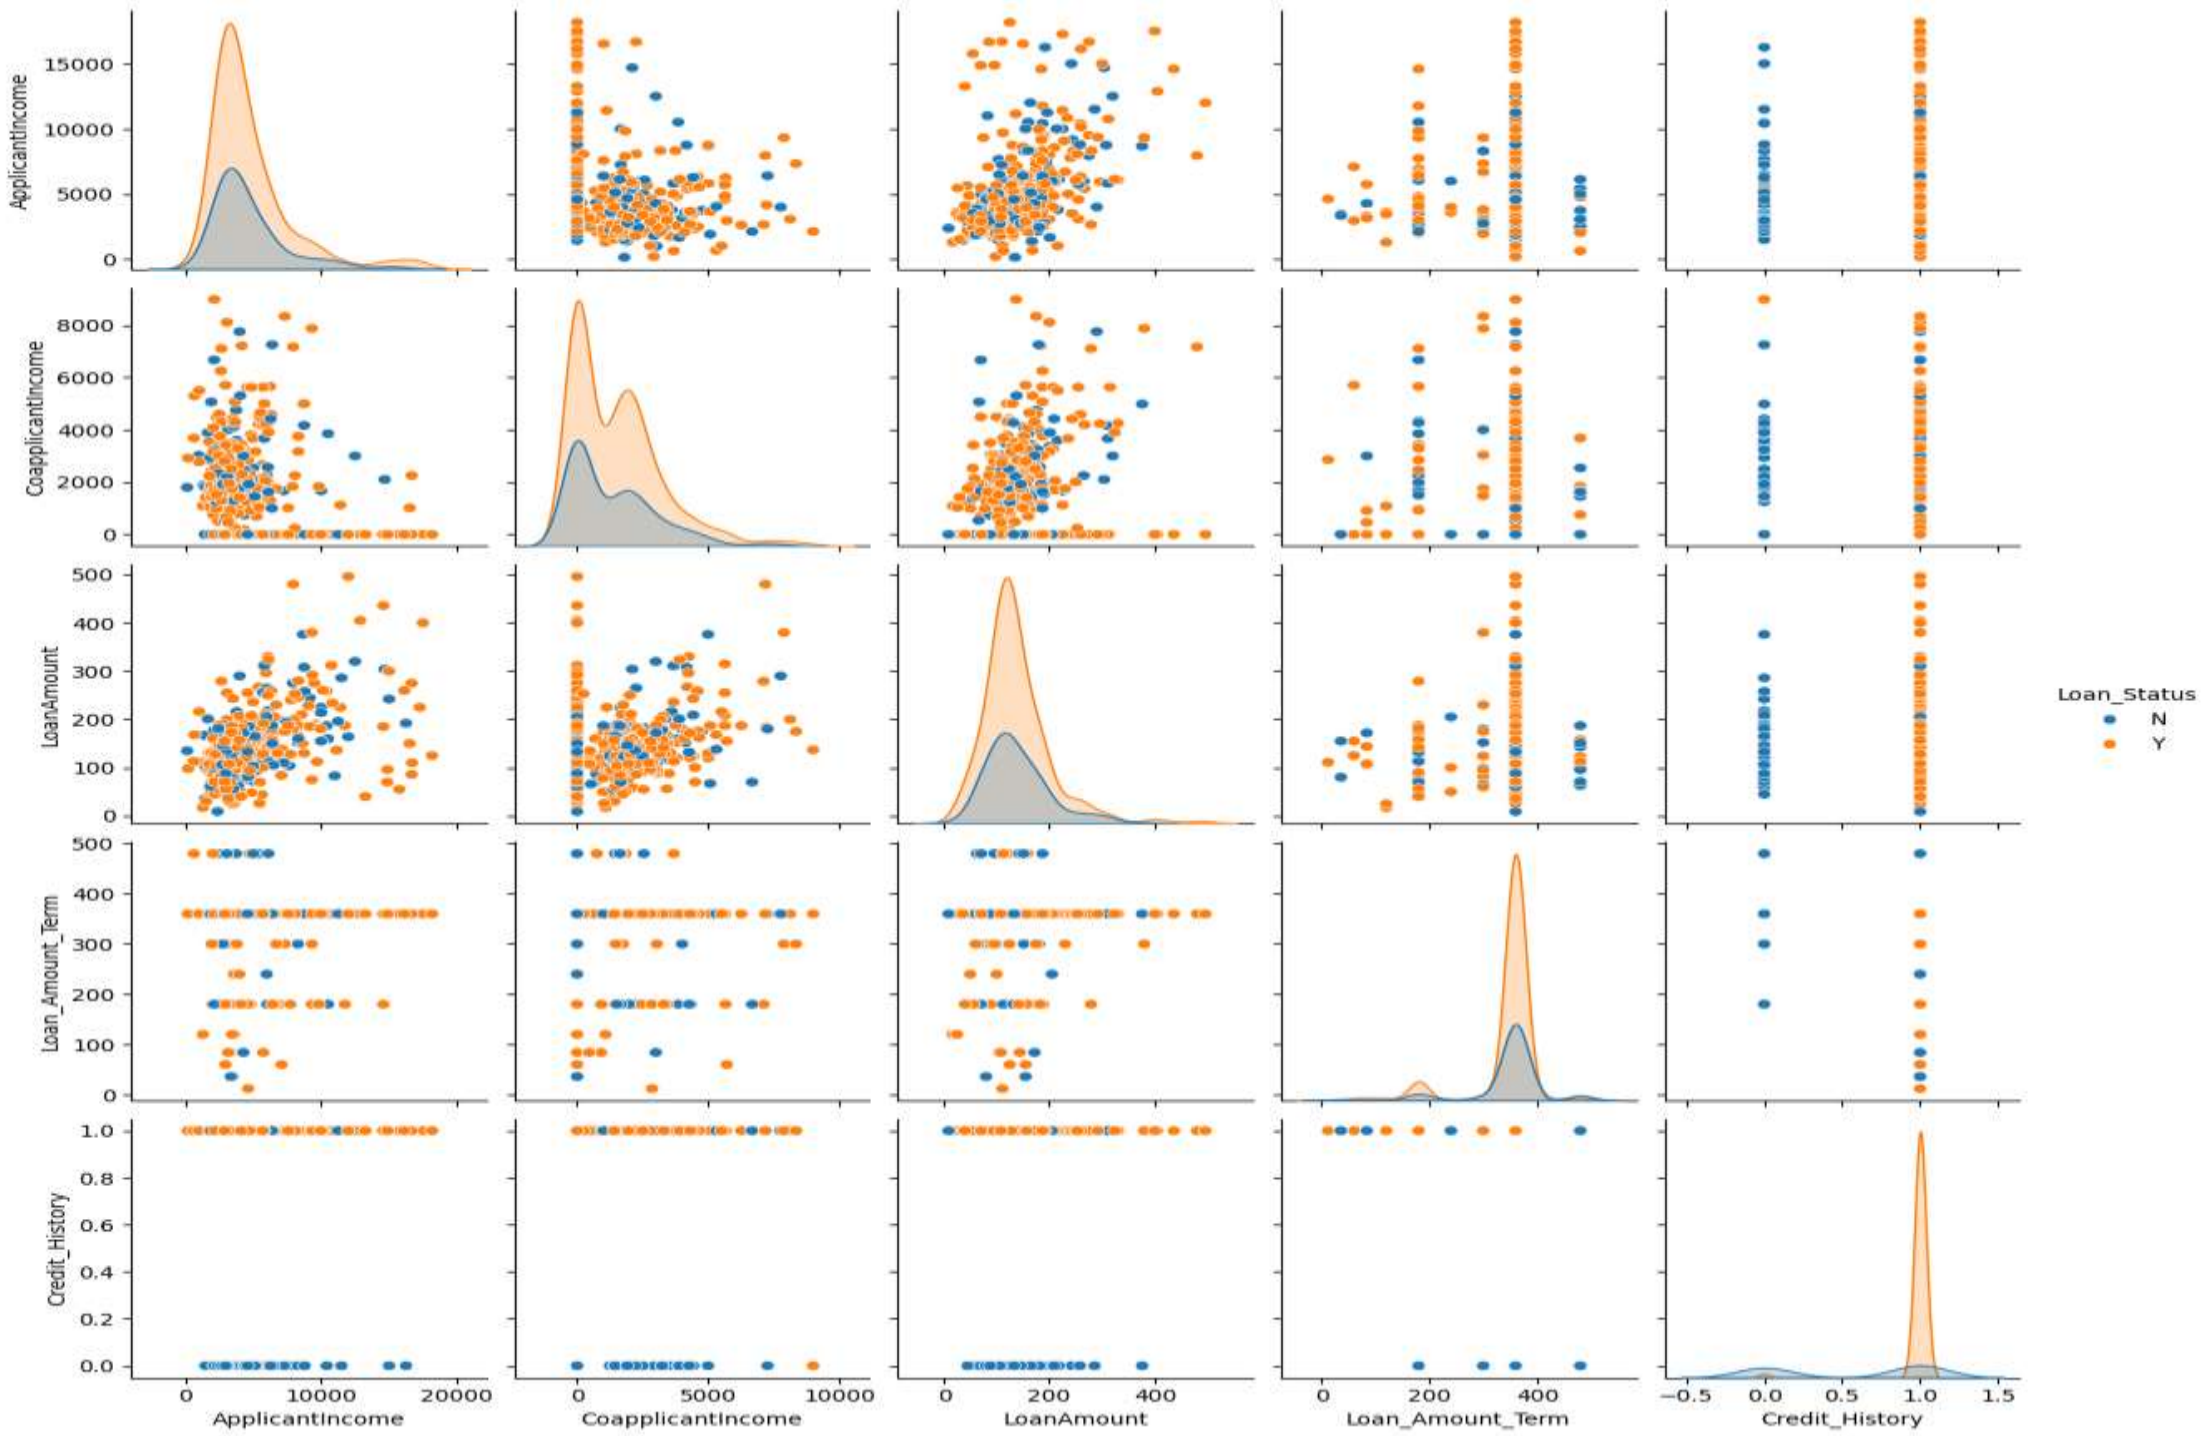
ApplicantIncome
CoapplicantIncome
LoanAmount
Loan_Amount_Term
Credit_History
Loan_Status
N
Y

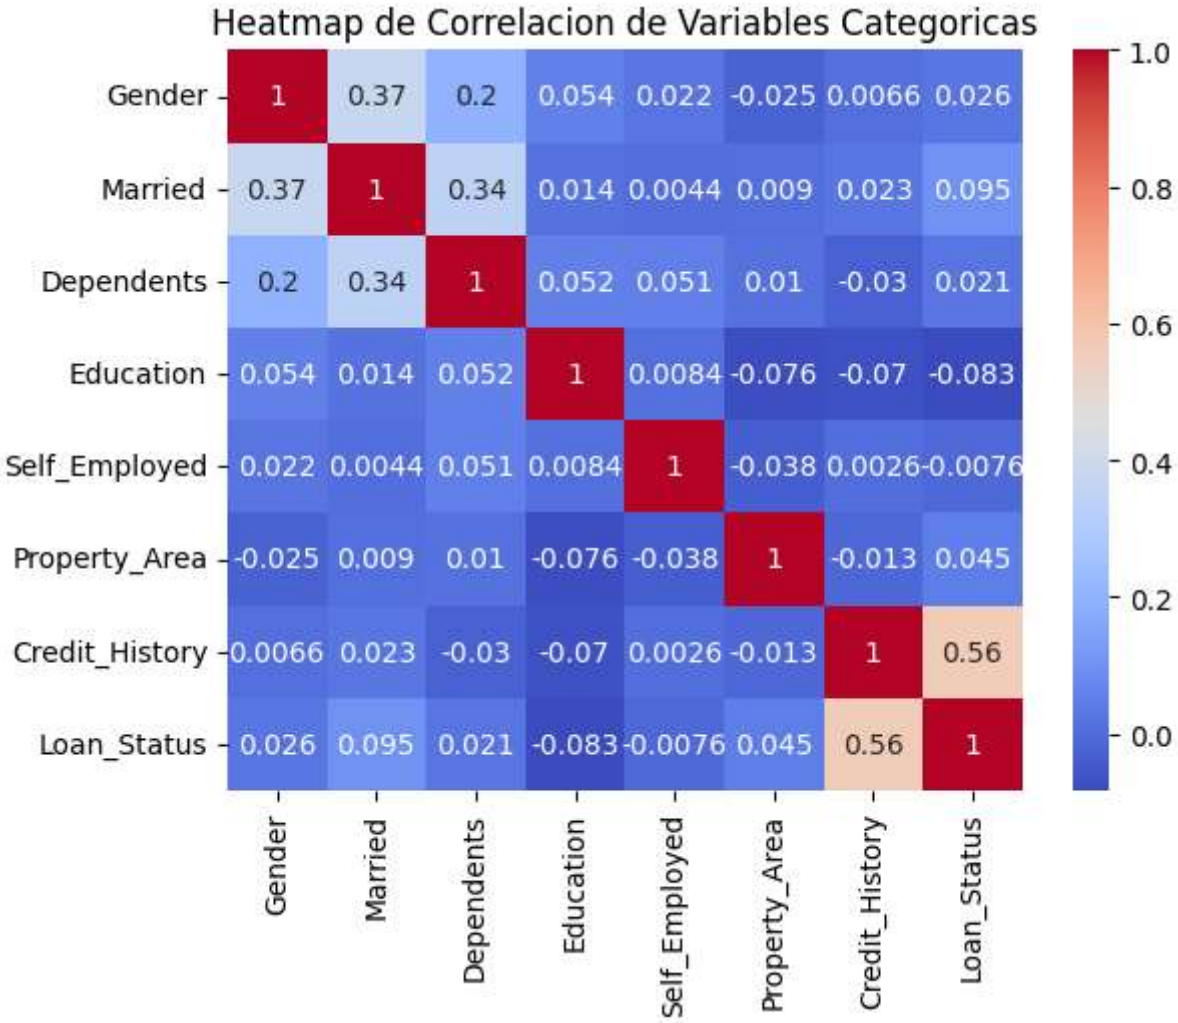

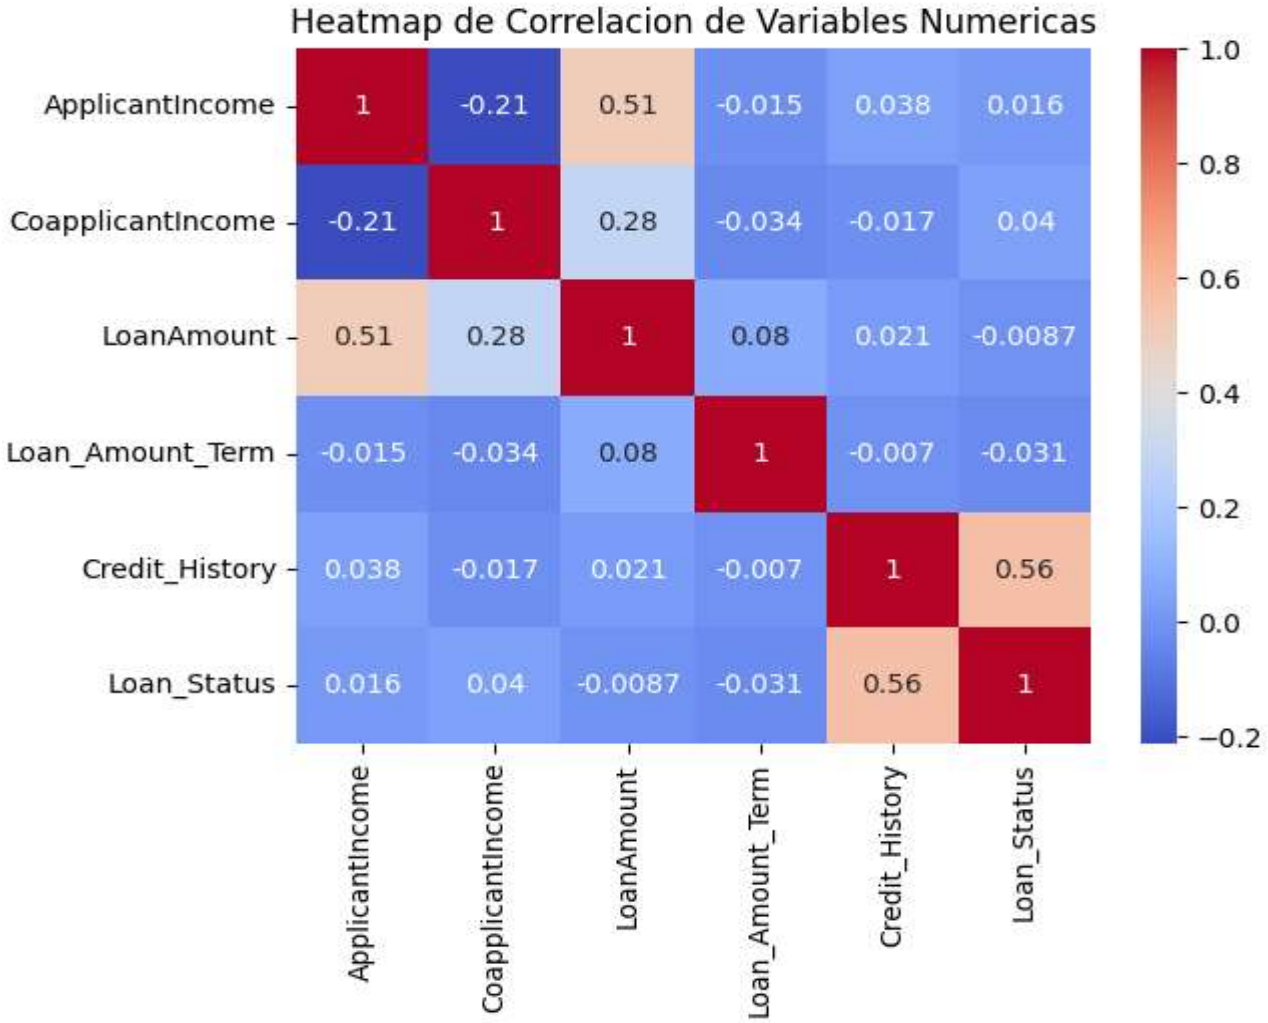

Se puede observar que muchas de las variables presentes no tienen mucho valor significativo y es posible que las diferencias mostradas anteriormente hayan sido afectadas porque dichos clientes tenían un “*Credit_History*” positivo.

Encoding, Escalado y Features

```python
# Usaremos el LabelEncoder para convertir las variables categoricas a numericas
from sklearn import preprocessing
label_encoder = preprocessing.LabelEncoder()
df["Loan_Status"] = label_encoder.fit_transform(df["Loan_Status"])
df["Gender"] = label_encoder.fit_transform(df["Gender"])
df["Married"] = label_encoder.fit_transform(df["Married"])
df["Education"] = label_encoder.fit_transform(df["Education"])
df["Property_Area"] = label_encoder.fit_transform(df["Property_Area"])
df["Dependents"] = label_encoder.fit_transform(df["Dependents"])
# Dependents ya era Categorica Numerica, pero para 3 o mas dependientes tenia el valor "3+"
# por lo que se simplifica en esta operacion.
df["Self_Employed"] = label_encoder.fit_transform(df["Self_Employed"])
```

```python
# Usaremos el StandardScaler para estandarizar las variables numericas.
from sklearn.preprocessing import StandardScaler
scaler = StandardScaler()
X_std = scaler.fit_transform(X)
```

Debido a lo significante que es la feature de “*Credit_History”* es posible que no se obtenga mucha diferencia al cambiar features en el modelo, pero aun así se usaran varias para tener una baseline y comparar.

Modelos utilizados (Baseline con Train-Test Split de 80/20):

Logistic Regression

```
Accuracy del modelo: 0.8347826086956521
Report del modelo:
              precision    recall  f1-score   support

           0       0.96      0.58      0.72        43
           1       0.80      0.99      0.88        72

    accuracy                           0.83       115
   macro avg       0.88      0.78      0.80       115
weighted avg       0.86      0.83      0.82       115

Confusion Matrix del modelo:
[[25 18]
 [ 1 71]]
```

Random Forest

```
Accuracy del modelo: 0.8260869565217391
Report del modelo:
              precision    recall  f1-score   support

           0       0.90      0.60      0.72        43
           1       0.80      0.96      0.87        72

    accuracy                           0.83       115
   macro avg       0.85      0.78      0.80       115
weighted avg       0.84      0.83      0.82       115

Confusion Matrix del modelo:
[[26 17]
 [ 3 69]]
```

KNN

```
Accuracy del modelo: 0.6347826086956522
Report del modelo:
              precision    recall  f1-score   support

           0       0.55      0.14      0.22        43
           1       0.64      0.93      0.76        72

    accuracy                           0.63       115
   macro avg       0.59      0.54      0.49       115
weighted avg       0.61      0.63      0.56       115

Confusion Matrix del modelo:
[[ 6 37]
 [ 5 67]]
```

SVM

```
Accuracy del modelo: 0.8347826086956521
Report del modelo:
              precision    recall  f1-score   support

           0       0.96      0.58      0.72        43
           1       0.80      0.99      0.88        72

    accuracy                           0.83       115
   macro avg       0.88      0.78      0.80       115
weighted avg       0.86      0.83      0.82       115

Confusion Matrix del modelo:
[[25 18]
 [ 1 71]]
```

Comparativa con Features seleccionadas y Train-Test split de 77/23:

Logistic Regression

```
Accuracy del modelo: 0.8484848484848485
Report del modelo:
              precision    recall  f1-score   support

           0       0.96      0.58      0.72        45
           1       0.82      0.99      0.90        87

    accuracy                           0.85       132
   macro avg       0.89      0.78      0.81       132
weighted avg       0.87      0.85      0.84       132

Confusion Matrix del modelo:
[[26 19]
 [ 1 86]]
```

Random Forest

```
Accuracy del modelo: 0.803030303030303
Report del modelo:
              precision    recall  f1-score   support

           0       0.81      0.56      0.66        45
           1       0.80      0.93      0.86        87

    accuracy                           0.80       132
   macro avg       0.80      0.74      0.76       132
weighted avg       0.80      0.80      0.79       132

Confusion Matrix del modelo:
[[25 20]
 [ 6 81]]
```

KNN

```
Accuracy del modelo: 0.8257575757575758
Report del modelo:
              precision    recall  f1-score   support

           0       0.89      0.56      0.68        45
           1       0.81      0.97      0.88        87

    accuracy                           0.83       132
   macro avg       0.85      0.76      0.78       132
weighted avg       0.84      0.83      0.81       132

Confusion Matrix del modelo:
[[25 20]
 [ 3 84]]
```

SVM

```
Accuracy del modelo: 0.8484848484848485
Report del modelo:
              precision    recall  f1-score   support

           0       0.96      0.58      0.72        45
           1       0.82      0.99      0.90        87

    accuracy                           0.85       132
   macro avg       0.89      0.78      0.81       132
weighted avg       0.87      0.85      0.84       132

Confusion Matrix del modelo:
[[26 19]
 [ 1 86]]
```

Resultados de CrossValidation:

Accuracy:

LogReg: 0.8521739130434782
KNN: 0.6869565217391305
RF: 0.808695652173913

LogReg: 0.8521739130434782
KNN: 0.6695652173913044
RF: 0.8347826086956521

LogReg: 0.7719298245614035
KNN: 0.631578947368421
RF: 0.7368421052631579

LogReg: 0.8070175438596491
KNN: 0.6754385964912281
RF: 0.8157894736842105

LogReg: 0.8333333333333334
KNN: 0.6929824561403509
RF: 0.8157894736842105

Recall:

LogReg: 1.0
KNN: 0.9125
RF: 0.925

LogReg: 0.9876543209876543
KNN: 0.9135802469135802
RF: 0.9382716049382716

LogReg: 0.975
KNN: 0.8625
RF: 0.9375

LogReg: 0.975
KNN: 0.925
RF: 0.9625

LogReg: 0.9875
KNN: 0.925
RF: 0.95

Conclusiones:

Se obtuvo un modelo con 85% de accuracy y un recall de 99%, aunque debido al peso que tiene el valor de "*Credit_History"* es posible que sea necesario conseguir datos donde no tenga un valor tan representativo del target, ya que a muy pocas excepciones si el "*Credit_History"* se encontraba como positivo se encontraba una alta probabilidad de aprobación en el préstamo.

Mientras esta medida para aprobar prestamos esta en lo correcto, elimina una gran cantidad de posibles clientes en el futuro, la meta del banco es seguir creciendo y si posee esa información es perfectamente razonable usarla como medida para prestamos.